

LAPORAN GROUP PROJECT DATA ANALYTICS

Bank Customer Churn Analysis



Oleh Kelompok 3 (LB01):

Dewi Kintia – 2802533882

Elizaveta Falisha Susanto – 2802530590

Keisa Putri Alisa – 2802456662

Muhammad Chesta Faiz Ferdiansyah – 2802522935

BAB I

PENDAHULUAN

1.1 Latar Belakang

Di era digitalisasi perbankan yang semakin kompetitif, mempertahankan nasabah lama (*customer retention*) jauh lebih efisien secara biaya dibandingkan dengan mengakuisisi nasabah baru (*customer acquisition*). Fenomena berpindahnya nasabah atau pemutusan layanan oleh nasabah dikenal sebagai *customer churn*. Tingginya angka *churn* merupakan indikator langsung adanya ketidakpuasan nasabah, lemahnya daya saing produk, atau agresifnya strategi kompetitor di pasar. Oleh karena itu, kemampuan untuk memprediksi nasabah yang berpotensi *churn* menjadi instrumen strategis yang sangat krusial bagi manajemen bank dalam menjaga stabilitas pendapatan dan profitabilitas jangka panjang.

Berdasarkan audit kualitas data awal pada Proyek Progres Analisis Data Perbankan ini, ditemukan bahwa dataset memiliki karakteristik *class imbalance* yang mencerminkan kondisi riil industri, di mana mayoritas nasabah (~79,6%) berstatus bertahan (*non-churn*), sementara terdapat ~20,4% nasabah yang memutuskan untuk keluar (*churn*). Angka *churn* sebesar 20,4% ini merupakan sinyal kritis bagi kesehatan bisnis bank.

Analisis EDA lebih lanjut menunjukkan beberapa pola anomali dan kerentanan sistemik pada loyalitas nasabah. Sebagai contoh, nasabah yang tidak aktif memiliki kecenderungan *churn* yang jauh lebih tinggi. Dari segi demografis, median usia nasabah yang *churn* berada di kisaran produktif-matang (40–50 tahun), dan secara geografis, wilayah Jerman menunjukkan tingkat kerawanan tertinggi dengan *churn rate* mencapai ~32,4%. Lebih mengkhawatirkan lagi, sebaran finansial menunjukkan bank justru berisiko kehilangan nasabah dengan aset atau saldo bernilai tinggi, serta nasabah yang memiliki jumlah produk berlebih (3 atau 4 produk) yang seluruhnya berujung pada status *churn*.

Untuk mengatasi tantangan ini, pendekatan berbasis data (*data-driven approach*) mutlak diperlukan. Melalui pemanfaatan teknik *Data Analytics* dan *Machine Learning*, data historis nasabah dapat ditransformasikan menjadi wawasan prediktif. Proyek ini berfokus pada pengembangan model klasifikasi analitik (menggunakan *Logistic Regression* sebagai *baseline* dan *Random Forest Classifier* sebagai model lanjutan) guna mendeteksi probabilitas *churn* nasabah secara dini, sehingga pihak bank dapat mengambil tindakan preventif yang tepat sasaran.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam analisis ini adalah sebagai berikut:

1. Bagaimana karakteristik, pola, dan faktor dominan yang memengaruhi keputusan *customer churn* pada nasabah bank ditinjau dari aspek demografis dan finansial?
2. Bagaimana efektivitas dan performa model klasifikasi analitik (*Logistic Regression* dan *Random Forest Classifier*) dalam memprediksi risiko *churn* nasabah secara akurat?
3. Rekomendasi strategis dan intervensi bisnis apa yang paling optimal diterapkan untuk menekan tingkat *churn* nasabah berdasarkan temuan analitik?

1.3 Tujuan Analisis

Tujuan analisis dan penyusunan laporan proyek ini adalah:

1. Mengidentifikasi tren tersembunyi dan faktor penentu utama pemicu *customer churn* melalui Exploratory Data Analysis (EDA) yang komprehensif.
2. Membangun, menguji, dan membandingkan performa model prediktif terbaik dengan mengevaluasi metrik akurasi, *recall*, *F1-score*, serta *Confusion Matrix*.
3. Merumuskan rekomendasi berbasis bukti (*analytical evidence*) yang dapat mendukung pengambilan keputusan manajemen bank untuk mengoptimalkan strategi retensi nasabah.

1.4 Manfaat Analisis

Hasil dari proyek analisis data ini diharapkan dapat memberikan manfaat yang signifikan bagi berbagai pihak:

1. Bagi Pihak Manajemen Perbankan (Stakeholders)

Memberikan alat bantu keputusan (*decision support system*) yang objektif untuk memetakan nasabah yang rentan *churn*. Dengan mengetahui profil risiko secara spesifik—seperti nasabah bersaldo tinggi, nasabah di wilayah Jerman, atau nasabah dengan kompleksitas produk tertentu—bank dapat mengalokasikan anggaran pemasaran dan program loyalitas secara efisien dan tepat sasaran.

2. Bagi Praktisi dan Akademisi

Menjadi studi kasus nyata mengenai penerapan *end-to-end data pipeline*, mulai dari penanganan kualitas data, analisis hubungan antar-variabel, mitigasi masalah ketidakseimbangan kelas (*class imbalance*), hingga proses evaluasi dan *hyperparameter tuning* model klasifikasi.

BAB II LANDASAN TEORI

2.1 Customer Churn

Dalam industri perbankan yang dinamis, menjaga hubungan jangka panjang dengan nasabah merupakan pilar utama stabilitas bisnis. *Customer Churn* mendefinisikan fenomena di mana seorang nasabah memutuskan untuk menghentikan penggunaan layanan, menutup rekening, atau memindahkan aset finansialnya ke institusi kompetitor. Secara finansial, biaya yang dikeluarkan untuk mempertahankan nasabah yang sudah ada (*Customer Retention Cost*) jauh lebih rendah dibandingkan biaya untuk mengakuisisi nasabah baru (*Customer Acquisition Cost*). Tingginya angka *churn* merupakan indikator adanya friksi pada layanan atau ketidaksesuaian produk dengan kebutuhan pasar. Oleh karena itu, analisis prediktif terhadap perilaku *churn* berfungsi sebagai sistem peringatan dini agar manajemen dapat melakukan intervensi preventif secara berkala sebelum kehilangan nasabah potensial.

2.2 Data Preparation

Kualitas luaran dari model *machine learning* sangat bergantung pada kualitas data masukan (*garbage in, garbage out*). Oleh karena itu, tahapan penanganan kualitas data mutlak diperlukan untuk menjamin validitas hasil analisis.

2.2.1 Deteksi Outlier dengan Metode Interquartile Range (IQR)

Pencilan (*outlier*) adalah titik data yang menyimpang secara signifikan dari pola umum sebaran data lainnya. Keberadaan pencilan dapat mendistorsi parameter statistik dan menurunkan performa model prediktif. Metode *Interquartile Range* (IQR) merupakan teknik statistik non-parametrik yang digunakan untuk mendeteksi pencilan berdasarkan dispersi data. IQR dihitung dengan mencari selisih antara Kuartil Atas (Q_3) dan Kuartil Bawah (Q_1):

$$IQR = Q_3 - Q_1$$

Dengan batas bawah (*Lower Bound*) dan batas atas (*Upper Bound*) ditentukan menggunakan konstanta standar 1,5 sebagai berikut:

$$Batas\ Bawah = Q_1 - 1.5 \times IQR$$

$$Batas\ Atas = Q_3 + 1.5 \times IQR$$

Setiap observasi yang nilainya berada di luar rentang batas tersebut diklasifikasikan sebagai pencilan dan memerlukan tindakan penanganan, baik melalui penghapusan (*trimming*) maupun penyesuaian nilai.

2.2.2 Class Imbalance

Class Imbalance merupakan kondisi di mana distribusi jumlah sampel antar-kelas pada variabel target tidak proporsional secara signifikan. Dalam kasus prediksi *churn*, mayoritas data didominasi oleh kelas nasabah yang bertahan (kelas mayoritas), sedangkan kelas nasabah yang keluar (kelas minoritas) berjumlah jauh lebih sedikit. Jika kondisi ini diabaikan saat melatih model, algoritma cenderung mengalami bias ke arah kelas mayoritas. Akibatnya, model akan menghasilkan nilai akurasi yang tinggi secara semu, namun gagal total dalam mendeteksi nasabah yang sebenarnya berpotensi *churn*.

2.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) adalah pendekatan analitik yang bertujuan untuk memahami struktur data, mengidentifikasi anomali, menguji hipotesis, dan menemukan hubungan kausalitas antar-variabel melalui visualisasi dan ringkasan statistik. EDA terbagi menjadi 2 bagian, yaitu Analisis Univariat dan Analisis Bivariat & Multivariat.

Analisis Univariat berfokus pada visualisasi dan distribusi dari satu variabel tunggal (misalnya melihat sebaran usia nasabah). Sedangkan Analisis Bivariat dan Multivariat meneliti interaksi atau korelasi antara dua variabel atau lebih secara simultan. Dalam konteks ini, analisis bivariat digunakan untuk memetakan bagaimana variabel demografis (seperti wilayah geografis dan jenis kelamin) serta variabel finansial (seperti saldo rekening dan jumlah produk) memengaruhi variabel target *churn*.

2.4 Algoritma Classification

Proyek analitik ini mengimplementasikan dua pendekatan algoritma klasifikasi yang berbeda untuk memprediksi probabilitas nasabah yang akan keluar dari ekosistem perbankan.

2.4.1 Logistic Regression

Regresi Logistik merupakan algoritma klasifikasi linear yang digunakan untuk memprediksi probabilitas variabel dependen yang bersifat biner (seperti nilai 0 untuk non-churn dan 1 untuk churn). Berbeda dengan regresi linear konvensional, regresi logistik mentransformasikan hasil persamaan linear menggunakan fungsi Sigmoid (Logistik) agar *output* yang dihasilkan selalu berada dalam rentang nilai antara 0 dan 1. Persamaan matematika fungsi Sigmoid dinyatakan sebagai:

$$P(Y = 1) = \frac{1}{1 + e^{-z}}$$

Nilai probabilitas yang dihasilkan kemudian dikonversi menjadi label kelas berdasarkan nilai ambang batas (*threshold*) tertentu (umumnya 0,5). Regresi Logistik sering digunakan sebagai

model acuan awal (*baseline model*) karena strukturnya yang sederhana, komputasinya yang cepat, dan koefisiennya yang mudah diinterpretasikan.

Pada penelitian yang dijadikan acuan, Random Forest digunakan untuk memprediksi customer churn dan dibandingkan dengan Logistic Regression menggunakan metrik Accuracy, Precision, Recall, dan F1-Score. Hasil penelitian menunjukkan bahwa Random Forest memperoleh Accuracy sebesar 83,12%, Precision sebesar 84%, Recall sebesar 96%, dan F1-Score sebesar 90%. Hasil tersebut menunjukkan bahwa Random Forest memiliki performa yang lebih baik dibandingkan Logistic Regression, terutama dalam mengidentifikasi pelanggan yang berpotensi melakukan churn. Oleh karena itu, Random Forest dipilih sebagai salah satu model dalam penelitian ini karena memiliki kemampuan klasifikasi yang tinggi, mampu menangani hubungan yang kompleks antar variabel, serta menyediakan analisis feature importance untuk mengetahui fitur yang paling berpengaruh terhadap prediksi customer churn.

2.4.2 Random Forest Classifier

Random Forest Classifier adalah algoritma berbasis *ensemble learning* yang bekerja dengan membangun sekumpulan besar pohon keputusan (*Decision Trees*) secara independen selama fase pelatihan. Algoritma ini menerapkan dua prinsip utama, yaitu prinsip Bagging (Bootstrap Aggregating), dimana setiap pohon keputusan dilatih menggunakan sampel data acak yang diambil dengan pengembalian dari dataset asli, dan prinsip Random Feature Selection, dimana pada setiap percabangan (*node*) pohon, pemilihan fitur terbaik hanya dibatasi dari subset fitur acak yang dipilih secara acak.

Prediksi akhir dari *Random Forest* ditentukan melalui mekanisme pemungutan suara terbanyak (*majority voting*) dari seluruh pohon keputusan yang terbentuk. Pendekatan *ensemble* ini memberikan keunggulan berupa resistensi yang tinggi terhadap masalah *overfitting*, kemampuan menangani hubungan non-linear yang kompleks antar-fitur, serta stabilitas akurasi yang lebih superior dibandingkan model pohon tunggal.

2.4.3 Logistic Regression

Logistic Regression merupakan salah satu algoritma supervised learning yang banyak digunakan untuk menyelesaikan permasalahan klasifikasi biner, termasuk prediksi customer churn. Algoritma ini bekerja dengan memodelkan hubungan antara variabel independen dan probabilitas suatu kejadian menggunakan fungsi logistik (sigmoid), sehingga mampu menghasilkan probabilitas suatu data termasuk ke dalam kelas tertentu. Selain memiliki proses pelatihan yang relatif cepat, Logistic Regression juga mudah diinterpretasikan karena setiap fitur memiliki koefisien yang menunjukkan arah dan besarnya pengaruh terhadap hasil prediksi.

Pada penelitian yang dijadikan acuan, Logistic Regression digunakan sebagai salah satu model untuk memprediksi customer churn dan dievaluasi menggunakan metrik Accuracy, Precision,

Recall, serta F1-Score. Hasil penelitian menunjukkan bahwa model Logistic Regression mampu mencapai Accuracy sebesar 76,85%, Precision sebesar 79%, Recall sebesar 94%, dan F1-Score sebesar 86%. Nilai recall yang tinggi menunjukkan bahwa model mampu mengidentifikasi sebagian besar pelanggan yang berpotensi churn, sehingga sesuai digunakan pada kasus klasifikasi yang mengutamakan kemampuan mendeteksi kelas positif. Oleh karena itu, Logistic Regression dipilih sebagai salah satu model dalam penelitian ini karena memiliki kemampuan prediksi yang baik, mudah diinterpretasikan, serta dapat dijadikan model pembandingan terhadap algoritma klasifikasi lainnya.

2.5 Metrik Evaluasi Kinerja Model Klasifikasi

Untuk mengukur efektivitas, reliabilitas, dan tingkat akurasi dari model prediktif yang dibangun, digunakan instrumen *Confusion Matrix* dan beberapa metrik turunan.

2.5.1 Confusion Matrix

Confusion Matrix adalah tabel kontingensi dua dimensi yang memetakan perbandingan antara label aktual (fakta riil di lapangan) dengan label yang diprediksi oleh model. Komponen utamanya terdiri dari:

1. True Positive (TP)

Nasabah yang secara aktual *churn* dan berhasil diprediksi dengan benar sebagai *churn* oleh model.

2. True Negative (TN)

Nasabah yang secara aktual setia (non-churn) dan berhasil diprediksi dengan benar sebagai non-churn oleh model.

3. False Positive (FP) / *Type I Error*

Nasabah yang secara aktual setia tetapi salah diprediksi sebagai nasabah yang akan *churn*.

4. False Negative (FN) / *Type II Error*

Nasabah yang secara aktual *churn* tetapi salah diprediksi sebagai nasabah yang setia.

2.5.2 Accuracy

Akurasi mengukur proporsi total prediksi benar (baik positif maupun negatif) terhadap keseluruhan total data.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Metrik ini kurang optimal dan dapat menyesatkan jika diterapkan pada kondisi *class imbalance*, karena model yang bias akan tetap menghasilkan nilai akurasi tinggi meskipun gagal mendeteksi kelas minoritas.

2.5.3 Precision

Presisi mengukur tingkat keakuratan model dalam memberikan prediksi positif. Metrik ini menunjukkan berapa banyak nasabah yang diprediksi *churn* yang pada kenyataannya memang benar-benar *churn*. Dirumuskan:

$$Precision = \frac{TP}{TP+FP}$$

2.5.4 Recall (Sensitivitas)

Recall mengukur kemampuan model dalam menjaring atau menemukan kembali seluruh sampel dari kelas positif aktual. Dalam studi *customer churn*, *recall* merupakan metrik yang paling kritikal karena meminimalkan angka *False Negative* (kondisi di mana bank luput mendeteksi nasabah yang sebenarnya akan pergi). Dirumuskan:

$$Recall = \frac{TP}{TP+FN}$$

2.5.5 F1-Score

F1-Score merupakan nilai rata-rata harmonis (*harmonic mean*) yang menyeimbangkan antara komponen *Precision* dan *Recall*. Metrik ini memberikan gambaran akurasi model yang lebih objektif, terutama ketika terdapat ketidakseimbangan yang signifikan antar-kelas data.


$$F1\ Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

2.5.6 Area Under the Receiver Operating Characteristic Curve (ROC-AUC)

Kurva ROC menggambarkan performa model klasifikasi pada seluruh ambang batas klasifikasi (*classification thresholds*) dengan memplot hubungan antara *True Positive Rate* pada sumbu Y dan *False Positive Rate* pada sumbu X. AUC (*Area Under the Curve*) mengukur seluruh area dua dimensi di bawah kurva ROC tersebut. Nilai AUC berkisar antara 0 hingga 1; semakin mendekati nilai 1, semakin baik kemampuan diskriminasi model dalam membedakan antara nasabah yang akan *churn* dengan nasabah yang tetap loyal.

BAB III METODOLOGI

3.1 Alur Penelitian



3.2 Input Data

Dataset yang digunakan dalam analisis ini mencakup 10.000 baris data dengan 12 kolom yang merepresentasikan profil nasabah. Secara garis besar, fitur-fitur di dalamnya terbagi menjadi tiga kategori utama, yaitu identitas nasabah, profil demografis, dan metrik keuangan. Variabel kunci meliputi *credit_score* (integer), *country* (object), *gender* (object), *age* (integer), *tenure* (integer), *balance* (float), *products_number* (integer), serta target variabel yaitu *churn* (float). Berdasarkan hasil pengecekan awal, tipe data pada setiap kolom sudah cukup representatif. Nilai numerik telah terdefinisi sebagai integer atau float, sementara data kategorikal tersimpan sebagai object atau string, sehingga dataset ini sudah siap untuk masuk ke tahap pra-pemrosesan lebih lanjut. Berikut hasil detail mengenai variabel:

Nama variabel	Data types	Keterangan	Value
customer_id	Integer	Identitas unik nasabah	15634602, 15647311, dst.

credit_score	Integer	Skor kelayakan kredit nasabah	350 – 850
country	Object	Lokasi negara tempat tinggal	France, Germany, Spain
gender	Object	Jenis kelamin nasabah	Female, Male
age	Integer	Usia nasabah	18 – 92 tahun
tenure	Integer	Lama menjadi nasabah (tahun)	0 – 10 tahun
balance	Float	Jumlah saldo di rekening nasabah	0.00 – 250,898.09
products_number	Integer	Jumlah produk bank yang digunakan	1, 2, 3, 4
credit_card	Integer	Kepemilikan kartu kredit	1 (Ya), 0 (Tidak)
active_member	Integer	Status keaktifan anggota	1 (Aktif), 0 (Tidak Aktif)
estimated_salary	Float	Estimasi gaji tahunan nasabah	11.58 – 199,992.48
churn	Float	Status nasabah berhenti (target)	1 (Churn), 0 (Stay)

3.3 Exploratory Data Analysis

Tahap ini merupakan fokus utama penulis untuk membedah karakteristik dataset secara mendalam. EDA dirancang tidak hanya untuk menampilkan ringkasan visual, melainkan untuk menggali pola perilaku, anomali, serta tren segmentasi nasabah yang memiliki kecenderungan paling tinggi untuk melakukan *churn*. Berdasarkan struktur dan alur implementasi pada kode program yang dijalankan, seluruh proses EDA dirancang untuk dieksplorasi melalui 8 skenario visualisasi yang terbagi ke dalam analisis univariat dan bivariat.

1. Analisis Karakteristik Nasabah (Univariat)

Analisis univariat diawali dengan menguji karakteristik tunggal dari variabel target melalui visualisasi distribusi *churn* vs *non-churn*. Pada tahap ini, grafik batang (*countplot*) digunakan untuk memeriksa perbandingan proporsi secara riil antara nasabah

yang mempertahankan layanan (0) dengan nasabah yang memutuskan keluar (1). Melalui perhitungan frekuensi agregat, perhitungan frekuensi kemunculan data dikonversi menjadi representasi visual untuk mendeteksi tingkat keparahan masalah *class imbalance*.

2. Analisis Pola Perilaku dan Demografi Terhadap Hubungan Churn (Bivariat & Segmentasi)

Setelah karakteristik target dipetakan, analisis ditingkatkan ke skala bivariat dan segmentasi untuk mengkorelasikan variabel prediktor terhadap status *churn* nasabah. Aspek perilaku dan demografi diuji pertama kali melalui visualisasi aktivitas nasabah terhadap *churn*. Dengan mengaitkan status keaktifan (*active_member*) dengan variabel target, grafik ini berfungsi menguji hipotesis awal mengenai pengaruh interaksi fisik nasabah terhadap tingkat retensi perbankan. Pengujian demografi kemudian diperdalam lewat visualisasi usia nasabah (*age*) menggunakan sebaran distribusi seperti *boxplot*. Langkah ini ditujukan untuk memetakan rentang usia kritis yang paling rentan melakukan *churn*, sekaligus mempermudah deteksi nilai pencilan (*outliers*) pada karakteristik umur nasabah. Sementara untuk faktor geografis, analisis membedah variabel negara asal (*country*) untuk melihat sebaran volume total nasabah yang keluar di wilayah Prancis, Spanyol, dan Jerman.

Eksplorasi bivariat berikutnya berfokus pada indikator finansial dan kepemilikan produk untuk melihat korelasi yang lebih sensitif terhadap loyalitas. Visualisasi saldo rekening (*balance*) dirancang menggunakan *boxplot* untuk meneliti sebaran nominal uang yang mengendap pada kelompok nasabah yang bertahan dan yang keluar. Visualisasi ini sangat penting untuk melihat apakah nasabah dengan saldo tinggi cenderung lebih loyal atau justru sebaliknya. Selanjutnya, faktor loyalitas jangka panjang diukur melalui visualisasi masa keanggotaan (*tenure*) terhadap *churn*, untuk melihat keterkaitan antara durasi menjadi pelanggan dengan tingkat kejenuhan nasabah. Untuk melihat kompleksitas layanan, visualisasi jumlah produk (*products_number*) dilibatkan untuk mendeteksi apakah banyaknya produk yang diambil nasabah berbanding lurus dengan kepuasan atau justru memicu kerentanan untuk *churn*. Terakhir, visualisasi persentase *churn* per wilayah dengan menggunakan perhitungan nilai persentase agregat (*churn rate*).

3.4 Modelling

3.4.1 Random Forest Classifier

Setelah pola data berhasil dipetakan melalui proses eksplorasi data (EDA), tahapan berikutnya difokuskan pada pembangunan model prediktif berbasis *machine learning*. Proses ini dirancang untuk menguji efisiensi algoritma klasifikasi dalam memprediksi potensi *churn* nasabah, dengan menempatkan *Random Forest Classifier* sebagai algoritma utama dalam skenario eksperimen.

Proses pemodelan dirancang untuk diawali dengan melakukan pembagian data (*data splitting*) menggunakan mekanisme pembagian data acak yang terstandarisasi. Persentase pembagian yang direncanakan adalah sebesar 80% untuk data latih (*training set*) dan 20% sisanya dialokasikan sebagai data uji (*testing set*). Pembagian dengan rasio ini dipilih untuk memastikan bahwa model mendapatkan volume data yang cukup untuk mempelajari karakteristik *churn* pada fase latihan, sekaligus menyisakan data uji yang representatif guna mengevaluasi performa model secara objektif pada data baru yang belum pernah dilihat sebelumnya.

Sebelum model utama dikembangkan, langkah berikutnya adalah menginisialisasi model acuan (*baseline model*) menggunakan algoritma *Logistic Regression*. Langkah ini diambil sebagai tolak ukur awal untuk melihat sejauh mana batas pemisah linear mampu mengklasifikasikan status *churn* nasabah. Dari hasil performa *baseline model* tersebut, pengujian kemudian ditingkatkan ke model utama yaitu *Random Forest Classifier*. Pemilihan algoritma *Random Forest* ini didasarkan pada karakteristik data perbankan yang cenderung kompleks, memiliki dimensi fitur yang beragam, serta sering kali memuat hubungan non-linear antar variabelnya, seperti pola interaksi antara variabel jumlah produk dan saldo nasabah yang tidak dapat ditangani dengan baik oleh model linear biasa.

Pengembangan model *Random Forest* ini dirancang untuk menerapkan tiga mekanisme teknis utama secara berurutan. Pertama, algoritma dikonfigurasi menggunakan konsep *ensemble learning* melalui metode *Bootstrap Aggregating* (Bagging). Melalui mekanisme ini, dataset akan disampel ulang secara acak dengan pengembalian untuk membangun sekumpulan pohon keputusan (*decision trees*) yang independen satu sama lain. Kedua, dilakukan perancangan pembatasan pemilihan fitur secara acak pada setiap percabangan pohon untuk mereduksi risiko terjadinya *overfitting*. Skenario pembatasan fitur ini sangat diandalkan untuk menekan nilai varians model, sehingga model tidak sekadar menghafal pola spesifik pada data latihan melainkan tetap memiliki kemampuan generalisasi yang tinggi saat diuji dengan data nasabah baru. Terakhir, model mengintegrasikan mekanisme *voting* untuk menentukan keputusan klasifikasi akhir. Prediksi akhir dari status *churn* nasabah akan diputuskan berdasarkan suara terbanyak (*majority voting*) dari seluruh pohon keputusan yang telah terbentuk. Penggabungan prediksi dari sekumpulan pohon keputusan ini difungsikan untuk menghasilkan stabilitas serta akurasi prediksi yang jauh lebih tinggi dibandingkan jika hanya mengandalkan satu pohon keputusan tunggal.

3.4.2 Logistic Regression

Logistic Regression merupakan salah satu algoritma *supervised learning* yang digunakan untuk menyelesaikan permasalahan klasifikasi biner dengan memodelkan hubungan antara variabel independen dan variabel dependen menggunakan fungsi logistik (sigmoid). Algoritma ini menghasilkan nilai probabilitas yang kemudian digunakan untuk menentukan kelas prediksi berdasarkan ambang batas tertentu. Logistic Regression dipilih dalam penelitian ini karena

memiliki kemampuan interpretasi yang baik melalui nilai koefisien pada setiap fitur, sehingga arah dan besarnya pengaruh masing-masing variabel terhadap kemungkinan terjadinya *customer churn* dapat dianalisis secara jelas.

Pada penelitian ini, Logistic Regression digunakan untuk membangun model prediksi *customer churn* berdasarkan data pelanggan yang telah melalui tahap prapemrosesan. Model dilatih menggunakan data latih (*training set*) untuk mempelajari pola hubungan antara atribut pelanggan dengan status *churn*, kemudian dievaluasi menggunakan data uji (*testing set*) untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dipelajari sebelumnya. Evaluasi performa model dilakukan menggunakan metrik Accuracy, Precision, Recall, F1-Score, serta Confusion Matrix untuk memberikan gambaran mengenai hasil klasifikasi pada setiap kelas. Selain itu, dilakukan analisis terhadap feature coefficient untuk mengidentifikasi fitur-fitur yang memberikan pengaruh positif maupun negatif terhadap prediksi *customer churn*.

3.5 Evaluasi Model

Setelah proses pelatihan model selesai, dilakukan tahap evaluasi untuk mengukur kemampuan model dalam melakukan klasifikasi terhadap data yang belum pernah dipelajari sebelumnya. Evaluasi dilakukan menggunakan beberapa metrik klasifikasi, yaitu Accuracy, Precision, Recall, F1-Score, Confusion Matrix, dan Receiver Operating Characteristic - Area Under the Curve (ROC-AUC). Penggunaan beberapa metrik evaluasi bertujuan untuk memberikan gambaran performa model secara menyeluruh, terutama dalam menangani permasalahan klasifikasi *customer churn* yang berpotensi memiliki distribusi kelas yang tidak seimbang.

Accuracy digunakan untuk mengukur proporsi keseluruhan prediksi yang benar terhadap seluruh data pengujian. Meskipun metrik ini memberikan gambaran umum mengenai performa model, accuracy saja belum cukup untuk mengevaluasi model pada kasus klasifikasi dengan distribusi kelas yang tidak seimbang. Oleh karena itu, digunakan metrik tambahan berupa Precision, Recall, dan F1-Score. Precision menunjukkan kemampuan model dalam menghasilkan prediksi positif yang benar, sedangkan Recall mengukur kemampuan model dalam mengidentifikasi seluruh data yang benar-benar termasuk ke dalam kelas positif. Sementara itu, F1-Score merupakan rata-rata harmonis antara Precision dan Recall sehingga mampu memberikan ukuran performa yang lebih seimbang.

Selain menggunakan metrik evaluasi numerik, penelitian ini juga memanfaatkan Confusion Matrix untuk memberikan informasi mengenai jumlah prediksi benar dan salah pada setiap kelas. Melalui Confusion Matrix dapat diketahui nilai True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN), sehingga kesalahan klasifikasi dapat dianalisis secara lebih rinci. Selanjutnya, ROC-AUC digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas positif dan negatif berdasarkan nilai probabilitas yang dihasilkan. Nilai ROC-AUC yang semakin mendekati 1 menunjukkan bahwa model memiliki kemampuan diskriminasi yang semakin baik dalam mengklasifikasikan data *customer churn*.

3.6 Hyperparameter Tuning and Cross-Validation

Hyperparameter tuning merupakan proses optimasi parameter model yang dilakukan sebelum proses pelatihan untuk memperoleh konfigurasi model yang memberikan performa terbaik. Berbeda dengan parameter yang dipelajari secara otomatis selama proses pelatihan, hyperparameter ditentukan sebelum model dilatih dan berpengaruh terhadap kompleksitas serta kemampuan model dalam melakukan generalisasi. Pada penelitian ini, proses hyperparameter tuning dilakukan untuk meningkatkan performa model serta mengurangi potensi *overfitting* maupun *underfitting*.

Proses optimasi dilakukan menggunakan metode Cross-Validation. Metode ini bekerja dengan mengevaluasi seluruh kombinasi hyperparameter yang telah ditentukan, kemudian memilih kombinasi terbaik berdasarkan nilai metrik evaluasi yang diperoleh selama proses validasi. Pada model Random Forest, beberapa hyperparameter yang dioptimalkan meliputi jumlah pohon (*n_estimators*), kedalaman maksimum pohon (*max_depth*), jumlah minimum sampel untuk melakukan pemisahan (*min_samples_split*), jumlah minimum sampel pada setiap daun (*min_samples_leaf*), serta jumlah fitur yang dipertimbangkan pada setiap proses pemisahan (*max_features*).

Untuk memastikan bahwa model yang dihasilkan memiliki kemampuan generalisasi yang baik, proses hyperparameter tuning dikombinasikan dengan k-fold cross-validation. Pada metode ini, data pelatihan dibagi menjadi beberapa subset (*fold*), kemudian model dilatih menggunakan sebagian subset dan divalidasi pada subset lainnya secara bergantian hingga seluruh subset digunakan sebagai data validasi. Nilai performa dari setiap fold kemudian dirata-ratakan untuk menghasilkan estimasi performa model yang lebih stabil dan tidak bergantung pada satu pembagian data tertentu. Kombinasi hyperparameter dengan nilai evaluasi terbaik selanjutnya digunakan sebagai model akhir yang akan dievaluasi menggunakan data pengujian.

3.7 Output Data

Output dari penelitian ini adalah model klasifikasi *customer churn* yang telah melalui proses pelatihan, optimasi hyperparameter, dan evaluasi performa. Model yang dihasilkan mampu melakukan prediksi terhadap status *customer churn* berdasarkan data pelanggan. Selain itu, penelitian ini menghasilkan nilai evaluasi model yang meliputi Accuracy, Precision, Recall, F1-Score, ROC-AUC, serta Confusion Matrix untuk mengukur performa klasifikasi. Sebagai pendukung interpretasi model, penelitian ini juga menghasilkan analisis feature coefficient pada Logistic Regression dan feature importance pada Random Forest untuk mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi *customer churn*. Hasil tersebut kemudian digunakan sebagai dasar dalam membandingkan performa kedua model serta menentukan model yang memiliki kemampuan prediksi terbaik. Selain itu, dari berbagai eksplorasi yang telah dilakukan, dihasilkan temuan-temuan yang akan bermanfaat dalam pengambilan keputusan bisnis dan dapat digali lebih dalam lagi untuk proses analisis selanjutnya.

BAB IV IMPLEMENTASI

4.1 Environment Setup

Seluruh proses eksekusi dan implementasi teknis pada proyek analisis data ini dijalankan menggunakan *Jupyter Notebook*. Environment ini dipilih karena menyediakan ekosistem yang optimal untuk menjalankan bahasa pemrograman Python 3 secara modular, sehingga mempermudah proses dokumentasi kode, visualisasi data, hingga pelatihan model prediktif dalam satu dokumen. Untuk mendukung setiap tahapan kerja, mulai dari manipulasi data, analisis eksploratif, hingga pemodelan, beberapa *libraries* eksternal Python diintegrasikan ke dalam sistem program sebagai berikut:

1. Python Data Analysis Library (Pandas)

Pandas berfungsi sebagai alat utama dalam manajemen dan manipulasi data terstruktur. Melalui Pandas, dataset mentah dimuat ke dalam arsitektur *DataFrame* untuk mempermudah proses pembersihan data, pengelolaan indeks, serta transformasi variabel.

2. Numerical Python (NumPy)

Untuk mendukung kinerja komputasi numerik di balik struktur data tersebut, digunakan *library* NumPy. NumPy menyediakan fungsi manipulasi *array* multi-dimensi serta operasi matematika tingkat lanjut yang mempercepat pemrosesan statistik selama eksperimen berlangsung.

3. Matplotlib & Seaborn

Pada tahap analisis eksploratif (EDA), visualisasi data dibangun dengan mengkombinasikan dua *library* utama, yaitu Matplotlib dan Seaborn. Matplotlib digunakan sebagai fondasi dasar untuk mengatur tata letak, ukuran kanvas, serta elemen visual makro pada grafik. Di atas fondasi tersebut, Seaborn diaplikasikan untuk menghasilkan visualisasi statistik tingkat tinggi yang lebih informatif dan mudah dipahami, seperti pembuatan grafik distribusi *boxplot* dan *countplot* yang dilengkapi dengan pemisahan warna kategorikal (*hue*) untuk membedakan karakteristik antar kelompok nasabah.

4. Scikit-Learn (sklearn)

Untuk membangun seluruh arsitektur *machine learning*, peneliti menggunakan *library* Scikit-Learn (*sklearn*). *Library* ini memegang peran fundamental mulai dari tahap awal pemodelan hingga evaluasi akhir. Dalam proyek ini, Scikit-Learn diimplementasikan secara intensif untuk menjalankan fungsi pembagian dataset (*data splitting*),

menginisialisasi model acuan berupa Regresi Logistik, mengembangkan algoritma utama Random Forest Classifier, melakukan validasi silang (*Cross-Validation*), hingga mengeluarkan metrik evaluasi untuk mengukur kinerja dan akurasi model yang telah dilatih.

4.2 Data Input

Dataset yang digunakan adalah `Bank_Customer_Churn_Prediction_FinalCleaned.csv` yang memuat 9996 baris observasi dan 12 kolom variabel. Dataset ini telah melewati proses pembersihan data pada tahap sebelumnya sehingga tidak ditemukan nilai hilang maupun data duplikat pada pemeriksaan awal. Tipe data pada setiap kolom sudah representatif: variabel numerik terdefinisi sebagai integer atau float, sementara variabel kategorikal tersimpan sebagai object. Dengan demikian, dataset dinyatakan siap untuk masuk ke tahap pra-pemrosesan lebih lanjut.


4.3 Exploratory Data Analysis (EDA)

1. Distribusi Target Variabel (Churn vs Non-Churn)

```
# Plot 1: Distribusi Target Variabel (Churn vs Non-Churn)
plt.figure(figsize=(6, 4))
ax = sns.countplot(x='churn', data=df, palette=palette_colors)
plt.title("Distribusi Proporsi Churn Nasabah Bank", fontsize=12, fontweight='bold')
plt.xlabel("Status Churn (0: Bertahan, 1: Keluar)")
plt.ylabel("Jumlah Nasabah")
for p in ax.patches:
    ax.annotate(f'{p.get_height()}', (p.get_x() + p.get_width() / 2., p.get_height()),
               ha='center', va='center', xytext=(0, 5), textcoords='offset points')
plt.tight_layout()
plt.show()
```

Gambar 4.3.1

Gambar 4.3.1 adalah implementasi kode untuk menampilkan grafik distribusi target variabel. Kode ini bertujuan untuk mengecek proporsi label kelas pada variabel target, sehingga bisa mengidentifikasi kondisi *class imbalance*.



Gambar 4.3.2

Visualisasi distribusi variabel target pada Gambar 4.3.2 memperlihatkan adanya dominasi yang cukup kontras pada kelompok nasabah yang mempertahankan layanan (status *non-churn* atau kelas 0). Jumlah nasabah pada kelas mayoritas ini mencapai sekitar 7.960 orang atau setara dengan 79,6% dari total dataset. Di sisi lain, kelompok nasabah yang memutuskan untuk berhenti menggunakan layanan bank (status *churn* atau kelas 1) tercatat sebanyak 2.040 nasabah atau sekitar 20,4%. Ketimpangan proporsi dengan rasio mendekati 80:20 ini mengkonfirmasi adanya kendala ketidakseimbangan kelas (*class imbalance*) pada dataset. Tingkat *churn* yang menyentuh angka 20,4% ini menjadi catatan penting, karena jika data langsung dimasukkan ke dalam model tanpa *preprocessing* tambahan, algoritma klasifikasi dikhawatirkan akan bias dan cenderung hanya mengenali pola dari kelas mayoritas saja.

Ketika temuan ini dianalisis lebih lanjut dengan mengorelasikannya terhadap grafik bivariat lainnya, terlihat kecenderungan bahwa tingginya angka penutupan akun ini berpusat pada segmen nasabah yang memiliki status tidak aktif (*inactive member*) serta kelompok nasabah di wilayah Jerman. Fenomena ini mengindikasikan adanya kendala pada strategi retensi produk perbankan di wilayah tersebut. Pihak manajemen bank menghadapi tantangan besar dalam menjaga keterikatan (*engagement*) nasabah, mengingat rata-rata 1 dari 5 nasabah pada dataset ini memutuskan untuk menyudahi hubungan kemitraan mereka dengan bank.


2. Aktivitas Nasabah vs Churn

```
# Plot 2: Hubungan antara Aktivitas Nasabah dan Churn

plt.figure(figsize=(7, 4))
sns.countplot(x='active_member', hue='churn', data=df, palette=palette_colors)
plt.title("Analisis Churn Berdasarkan Status Keaktifan Nasabah", fontsize=12, fontweight='bold')
plt.xlabel("Status Anggota Aktif (0: Tidak Aktif, 1: Aktif)")
plt.ylabel("Jumlah Nasabah")
plt.legend(title="Status Churn", labels=["Bertahan", "Keluar"])
plt.tight_layout()
plt.show()
```

Gambar 4.3.3

Gambar 4.3.3 adalah implementasi kode untuk menampilkan grafik hubungan antara aktivitas nasabah dan churn. Tujuannya adalah untuk melihat dampak status keaktifan nasabah terhadap keputusan pemutusan layanan.



Gambar 4.3.4

Berdasarkan visualisasi pada Gambar 4.3.4, hubungan antara keaktifan nasabah (Active Member) dengan status churn menunjukkan adanya perbedaan pola perilaku yang cukup kontras. Kelompok nasabah yang diklasifikasikan tidak aktif (nilai 0) tercatat memiliki frekuensi churn yang jauh lebih tinggi dibandingkan dengan kelompok nasabah yang aktif (nilai 1). Pola ini mengindikasikan bahwa penurunan intensitas interaksi atau ketiadaan aktivitas transaksi pada layanan bank dapat menjadi indikator awal (*leading indicator*) yang kuat bahwa nasabah tersebut cenderung sedang berada dalam fase transisi sebelum akhirnya memutuskan untuk menutup akun.

Di dalam dataset ini, status `active_member` merepresentasikan interaksi finansial terakhir nasabah, seperti aktivitas transaksi kartu kredit, intensitas login pada aplikasi perbankan, ataupun riwayat mutasi rekening. Tingginya proporsi churn pada kelompok nasabah tidak aktif ini membuktikan secara empiris adanya kecenderungan di mana nasabah terlebih dahulu membiarkan rekening mereka mengendap tanpa aktivitas dalam jangka waktu tertentu, sebelum pada akhirnya benar-benar melakukan churn.


3. Usia Nasabah (*Age*) vs Churn

```
# Plot 3: Distribusi Usia terhadap Status Churn

plt.figure(figsize=(8, 4))
sns.boxplot(x='churn', y='age', data=df, palette=palette_colors)
plt.title("Distribusi Karakteristik Usia Terhadap Churn", fontsize=12, fontweight='bold')
plt.xlabel("Status Churn (0: Bertahan, 1: Keluar)")
plt.ylabel("Usia Nasabah (Tahun)")
plt.tight_layout()
plt.show()
```

Gambar 4.3.5

Gambar 4.3.5 merupakan implementasi visualisasi sebaran umur menggunakan diagram kotak (*boxplot*) dilakukan untuk mengidentifikasi konsentrasi umur nasabah yang rentan keluar.



Gambar 4.3.6

Berdasarkan grafik *boxplot* pada Gambar 4.3.1, terlihat perbedaan sebaran usia yang cukup jelas antara kelompok nasabah yang bertahan dengan nasabah yang melakukan *churn*. Nilai median usia untuk nasabah yang loyal berada di kisaran pertengahan 30 tahun, yang merepresentasikan kelompok usia muda atau awal masa produktif. Sebaliknya, nasabah yang memutuskan untuk *churn* memiliki median usia yang jauh lebih matang, di mana sebarannya terkonsentrasi kuat pada rentang usia 40 hingga 50 tahun. Pola ini menunjukkan adanya masalah retensi yang cukup serius pada segmen nasabah di usia dewasa-matang tersebut.

4. Wilayah Negara (Country) vs Churn

```
# Plot 4: Analisis Churn Berdasarkan Lokasi Nasabah

plt.figure(figsize=(8, 4))

sns.countplot(
    x='country',
    hue='churn',
    data=df,
    palette=palette_colors
)


plt.title(
    "Analisis Churn Berdasarkan Wilayah Nasabah",
    fontsize=12,
    fontweight='bold'
)
plt.xlabel("Wilayah")
plt.ylabel("Jumlah Nasabah")

plt.legend(
    title="Status Churn",
    labels=["Bertahan", "Keluar"]
)

plt.tight_layout()
plt.show()
```

Gambar 4.3.7

Implementasi kode pada Gambar 4.3.7 ini memetakan sebaran volume absolut nasabah yang keluar berdasarkan domisili geografis mereka.



Gambar 4.3.8

Melalui visualisasi pada Gambar 4.3.8, terlihat bahwa jika ditinjau dari total volume data keseluruhan, Prancis menempati posisi sebagai basis nasabah terbesar bagi bank. Namun, ketika dianalisis secara bivariat, grafik menunjukkan adanya pola anomali yang cukup jelas pada wilayah Jerman. Meskipun basis total nasabah di Jerman tidak sebanyak Prancis, jumlah absolut nasabah yang melakukan *churn* di Jerman terlihat hampir setara dengan total kasus *churn* di Prancis, serta jauh melampaui wilayah Spanyol. Fenomena ini mengindikasikan adanya kendala retensi yang bersifat lokal atau sistemik pada operasional bank khusus di area Jerman.

Kondisi tersebut menjadi lebih logis ketika dikaitkan dengan karakteristik data finansial, di mana nasabah asal Jerman secara statistik memiliki rata-rata saldo (*balance*) yang jauh lebih tinggi dan sebarannya lebih merata dibandingkan dengan negara lain. Tingginya angka *churn* di Jerman mengindikasikan bahwa bank kompetitor di pasar Jerman bergerak jauh lebih agresif dalam memberikan penawaran, seperti suku bunga yang lebih menarik atau layanan digital yang lebih mumpuni, yang akhirnya berhasil menarik perhatian kelompok nasabah bersaldo tinggi ini. Hal ini memperkuat dugaan adanya anomali operasional atau ketidakcocokan produk (*product mismatch*) yang terjadi khusus di pasar Jerman.

5. Saldo Rekening (Balance) vs Churn

```
# Plot 5: Distribusi Saldo terhadap Churn

plt.figure(figsize=(8, 4))


sns.boxplot(
    x='churn',
    y='balance',
    data=df,
    palette=palette_colors
)

plt.title(
    "Distribusi Saldo Nasabah terhadap Churn",
    fontsize=12,
    fontweight='bold'
)
plt.xlabel("Status Churn (0: Bertahan, 1: Keluar)")
plt.ylabel("Saldo Nasabah")

plt.tight_layout()
plt.show()
```

Gambar 4.3.9

Visualisasi *boxplot* pada Gambar 4.3.9 digunakan untuk menganalisis karakteristik kepemilikan aset finansial nasabah terhadap loyalitas mereka.



Gambar 4.3.10

Berdasarkan analisis sebaran variabel saldo (*balance*) pada Gambar 4.3.10, ditemukan pola yang cukup krusial terkait aspek profitabilitas bank. Kelompok nasabah yang memutuskan untuk *churn* menunjukkan nilai median saldo yang lebih tinggi, dengan sebaran data yang cenderung mengumpul di area bernilai tinggi dibandingkan dengan kelompok nasabah yang bertahan. Sebaliknya, pada kelompok nasabah yang loyal, sebaran data justru tertarik ke bawah karena adanya konsentrasi nasabah yang memiliki saldo nol. Temuan ini mengindikasikan bahwa bank sedang menghadapi risiko besar kehilangan nasabah kategori *high-value* yang sebenarnya membawa arus kapital besar.

Jika diperhatikan pada grafik *boxplot*, median saldo milik nasabah yang *churn* terlihat jauh lebih tinggi daripada nasabah yang bertahan. Kondisi di mana kelompok nasabah bertahan justru didominasi oleh saldo bernilai nol menunjukkan indikasi bahwa nasabah

tidak melihat adanya keuntungan finansial yang signifikan untuk tetap mengendapkan uang mereka di bank ini. Secara karakteristik, kelompok nasabah bersaldo tinggi umumnya sangat sensitif terhadap variabel seperti suku bunga, biaya administrasi, maupun dampak inflasi. Ketika bank tidak mampu memberikan insentif atau imbal hasil (*return*) yang kompetitif pada dana yang mengendap tersebut, nasabah akan cenderung menarik kapital mereka untuk dialokasikan ke instrumen investasi atau lembaga perbankan lain yang dinilai lebih menguntungkan.

6. Masa Keanggotaan (Tenure) vs Churn

```
# Plot 6: Lama Menjadi Nasabah vs Churn

plt.figure(figsize=(8, 4))

sns.boxplot(
    x='churn',
    y='tenure',
    data=df,
    palette=palette_colors
)


plt.title(
    "Distribusi Masa Keanggotaan terhadap Churn",
    fontsize=12,
    fontweight='bold'
)

plt.xlabel("Status Churn (0: Bertahan, 1: Keluar)")
plt.ylabel("Tenure (Tahun)")

plt.tight_layout()
plt.show()
```

Gambar 4.3.11

Implementasi kode pada Gambar 4.3.11 ini menguji keterkaitan antara durasi (dalam satuan tahun) nasabah menggunakan layanan perbankan terhadap status loyalitas.



Gambar 4.3.12

Berdasarkan distribusi *tenure* pada Gambar 4.3.12, sebaran data menunjukkan pola yang relatif merata mulai dari tahun pertama (1) hingga tahun kesembilan (9). Angka *churn*

terlihat konstan di setiap tingkatan *tenure*, di mana nasabah baru maupun nasabah lama yang telah berada di dalam ekosistem perbankan selama bertahun-tahun tetap menunjukkan proporsi kelolosan yang seragam. Pola ini menandakan bahwa lamanya waktu menjadi pelanggan tidak serta-merta membangun kekebalan terhadap risiko *churn*, sehingga program retensi harus tetap dijalankan secara berkala tanpa memandang senioritas dari akun nasabah.

Kondisi *churn* yang konstan dan merata di setiap level *tenure* ini membuktikan bahwa faktor durasi keanggotaan tidak memberikan efek retensi otomatis bagi bank. Jika dihubungkan dengan variabel *products_number*, ada kemungkinan bahwa program promo atau pelayanan prima lebih berfokus di awal masa akuisisi nasabah baru saja. Seiring berjalannya waktu, terutama saat memasuki tahun kelima ke atas, kelompok nasabah lama cenderung kurang mendapatkan penawaran khusus atau justru dihadapkan pada skema biaya administrasi yang dirasa memberatkan. Akibatnya, nasabah senior merasa tidak ada nilai tambah (*value*) lebih untuk tetap bertahan dan akhirnya memilih untuk *churn* dengan rasio yang setara dengan nasabah baru. Dari fenomena ini, dapat disimpulkan bahwa loyalitas nasabah pada bank ini tidak terbentuk hanya berdasarkan faktor waktu keanggotaan saja.

7. Jumlah Kepemilikan Produk (Products Number) vs Churn

```
# Plot 7: Jumlah Produk yang Dimiliki vs Churn

plt.figure(figsize=(8, 4))

sns.countplot(
    x='products_number',
    hue='churn',
    data=df,
    palette=palette_colors
)


plt.title(
    "Analisis Churn Berdasarkan Jumlah Produk",
    fontsize=12,
    fontweight='bold'
)
plt.xlabel("Jumlah Produk")
plt.ylabel("Jumlah Nasabah")

plt.legend(
    title="Status Churn",
    labels=["Bertahan", "Keluar"]
)

plt.tight_layout()
plt.show()
```

Gambar 4.3.13

Visualisasi bivariat pada Gambar 4.3.13 ini mengevaluasi dampak diversifikasi atau kompleksitas layanan yang diambil oleh nasabah terhadap keputusan *churn*.



Gambar 4.3.14

Berdasarkan visualisasi jumlah produk pada Gambar 4.3.14, ditemukan pola perilaku nasabah yang cukup ekstrem terkait pemanfaatan produk perbankan. Kelompok nasabah yang memiliki 2 produk tercatat menunjukkan tingkat loyalitas yang paling stabil, di mana mayoritas besar dari mereka berada pada status bertahan. Sebaliknya, nasabah yang hanya menggunakan 1 produk memiliki rasio *churn* yang relatif lebih tinggi. Namun, anomali yang paling kontras terlihat pada kelompok nasabah yang memiliki 3 atau 4 produk, di mana hampir seluruh data observasi mereka masuk ke dalam label kelas *churn*. Fenomena ini mengindikasikan bahwa strategi penjualan produk tambahan (*cross-selling*) yang terlalu agresif atau kompleksitas sistem yang membingungkan justru berdampak negatif dan memicu keputusan nasabah untuk menutup akun secara total.

Jika dianalisis dari sudut pandang pengalaman pengguna, kepemilikan 2 produk kemungkinan besar merupakan titik optimal bagi nasabah (misalnya kombinasi antara rekening tabungan dan kartu kredit) yang sudah cukup memenuhi kebutuhan finansial mereka tanpa terasa membebani. Ketika nasabah didorong untuk mengambil produk ketiga atau keempat, layanan yang diterima mungkin tidak lagi relevan atau justru dihadapkan pada akumulasi biaya administrasi yang berlipat ganda. Selain itu, banyaknya produk yang harus dikelola dalam satu waktu berisiko menurunkan tingkat kepuasan nasabah akibat rumitnya prosedur operasional bank, sehingga mereka memilih untuk menghentikan seluruh layanan dan beralih ke kompetitor.

8. Persentase Churn Per Wilayah (Churn Rate by Country)

```
# Plot 8: Persentase Churn per wilayah

churn_geo = pd.crosstab(
    df['country'],
    df['churn'],
    normalize='index'
) * 100


churn_geo[1].sort_values(ascending=False).plot(
    kind='bar',
    figsize=(8,4)
)

plt.title(
    "Persentase Churn per Wilayah",
    fontsize=12,
    fontweight='bold'
)
plt.ylabel("Persentase Churn (%)")
plt.xlabel("Wilayah")

plt.tight_layout()
plt.show()
```

Gambar 4.3.15

Implementasi kode pada Gambar 4.3.15 menunjukkan sebaran volume absolut geografis menjadi representasi persentase proporsional (*churn rate*) untuk mengunci wilayah dengan risiko tertinggi.



Gambar 4.3.16

Berdasarkan perhitungan nilai persentase agregat pada Gambar 4.3.16, visualisasi ini mempertegas temuan analisis geografis sebelumnya secara lebih valid. Wilayah Jerman mencatatkan tingkat kerawanan paling tinggi dengan proporsi *churn rate* mencapai angka 32,4%. Angka tersebut hampir dua kali lipat lebih besar jika dibandingkan dengan tingkat *churn* yang terjadi di Prancis sebesar 16,2% dan Spanyol sebesar 16,7%.

Informasi kuantitatif ini memperjelas fokus utama yang perlu diambil oleh manajemen perbankan. Tingginya rasio kehilangan nasabah di Jerman menunjukkan bahwa intervensi operasional, evaluasi terhadap kebijakan lokal, serta audit menyeluruh terhadap kualitas layanan penasihat keuangan ataupun platform digital di negara tersebut harus diprioritaskan. Langkah taktis ini sangat diperlukan untuk menghentikan laju perpindahan aset nasabah bersaldo tinggi ke bank kompetitor di pasar Jerman.

4.4 Modelling & Evaluating

4.4.1 Random Forest

1. Data Splitting

Sebelum algoritma dilatih, dataset dipisahkan secara acak menjadi data latih (*training set*) dan data uji (*testing set*) terlebih dahulu. Variabel prediktor seperti fitur demografis dan finansial dipisahkan dari variabel target, yaitu churn. Implementasi pemisahan ini dieksekusi menggunakan fungsi `train_test_split` dari pustaka `sklearn.model_selection`.

```
# 2. One-Hot Encoding untuk variabel kategorikal
df_encoded = pd.get_dummies(df_model, columns=['country', 'gender'], drop_first=True)

# 3. Pisahkan Fitur (X) dan Target (y)
X = df_encoded.drop(columns=['customer_id', 'churn'])
y = df_encoded['churn']

# 4. Train-Test Split - stratify=y agar proporsi churn seimbang di train & test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

Gambar 4.4.1.1.1

Proses pemisahan data di atas mengkonfigurasi parameter argumen `test_size=0.2`, yang berarti sistem secara ketat mengalokasikan 20% dari total data (2.000 baris observasi) sebagai data uji independen, sedangkan 80% sisanya (8.000 baris observasi) digunakan penuh sebagai basis pelatihan algoritma. Parameter `random_state=42` diintegrasikan ke dalam fungsi untuk mengunci generator angka acak. Penguncian ini menjamin bahwa pembagian baris data yang dihasilkan akan selalu konsisten dan sama persis setiap kali kode program dijalankan ulang, sehingga eksperimen bersifat dapat direplikasi (*reproducible*).

2. Random Forest Classifier

```
rf_model = RandomForestClassifier(
    n_estimators=200,
    max_depth=10,
    min_samples_leaf=5,
    class_weight='balanced',
    random_state=42,
    n_jobs=-1
)

rf_model.fit(X_train, y_train)
```

Gambar 4.4.1.2.1

Algoritma *Random Forest* diimplementasikan dengan memanggil fungsi `RandomForestClassifier()`. Pada kode program ini, inisialisasi awal menggunakan konfigurasi hyperparameter *default* dasar dari pustaka *scikit-learn*, dengan parameter

random_state=42 tetap disematkan untuk menjamin konsistensi pemilihan subset data acak pada setiap pembuatan cabang pohon keputusan. Saat perintah `rf_model.fit(X_train, y_train)` dijalankan, sistem secara teknis mengaktifkan metode Bootstrap Aggregating (Bagging) untuk mengambil sampel baris data latih secara acak dengan pengembalian. Bersamaan dengan itu, algoritma membentuk sekumpulan pohon keputusan independen di mana pada setiap percabangan (*node*), pemilihan variabel fitur dibatasi secara acak untuk menekan tingkat varians model. Setelah fungsi `.fit()` selesai dieksekusi, arsitektur model *Random Forest* telah matang dan siap memprediksi probabilitas status *churn* melalui mekanisme pemungutan suara terbanyak (*majority voting*) dari seluruh pohon keputusan yang terbentuk.

3. Hyperparameter Tuning

```
Fitting 5 folds for each of 50 candidates, totalling 250 fits
=== HASIL TUNING ===
Best F1 Score (CV) : 0.6292
Best ROC-AUC (CV) : 0.8628
Best Parameters   :
  n_estimators: 500
  min_samples_leaf: 5
  max_features: sqrt
  max_depth: 15
  class_weight: balanced_subsample
```

Gambar 4.4.1.3.1

Proses optimasi hyperparameter dilakukan menggunakan metode `RandomizedSearchCV` dari library `scikit-learn`. Berbeda dengan `GridSearchCV` yang menguji seluruh kombinasi parameter secara exhaustif, `RandomizedSearchCV` hanya mengambil sampel sebanyak 50 kombinasi secara acak dari ruang parameter yang telah ditentukan. Pendekatan ini dipilih karena jauh lebih efisien secara komputasional tanpa mengorbankan kualitas hasil pencarian secara signifikan.

Ruang pencarian mencakup lima hyperparameter utama: `n_estimators` (100, 200, 300, 500), `max_depth` (5, 8, 10, 15, None), `min_samples_leaf` (2, 5, 10, 20), `max_features` ('sqrt', 'log2', 0.5), dan `class_weight` ('balanced' atau 'balanced_subsample'). Proses pencarian dikonfigurasi dengan scoring multi-metrik yang merekam F1-Score dan ROC-AUC secara bersamaan, dengan `refit='f1'` sehingga model terbaik dipilih berdasarkan F1-Score — metrik yang paling relevan untuk data dengan kondisi class imbalance. Selain itu, threshold klasifikasi tidak diasumsikan selalu 0.5, melainkan disesuaikan menggunakan threshold optimal yang diturunkan dari kurva ROC melalui statistik Youden's J ($J = \text{TPR} - \text{FPR}$), sehingga model lebih sensitif dalam mendeteksi nasabah yang berpotensi churn.

4. Cross-Validation

```
=== HASIL CROSS-VALIDATION (5-Fold StratifiedKfold) ===

[ F1 Score per Fold ]
Fold 1: 0.5997
Fold 2: 0.6399
Fold 3: 0.6159
Fold 4: 0.6340
Fold 5: 0.6152
Mean  : 0.6209 ± 0.0144

[ ROC-AUC per Fold ]
Fold 1: 0.8541
Fold 2: 0.8703
Fold 3: 0.8673
Fold 4: 0.8601
Fold 5: 0.8558
Mean  : 0.8615 ± 0.0063
```

Gambar 4.4.1.4.1

Untuk memastikan robustness model terbaik hasil tuning, dilakukan evaluasi menggunakan StratifiedKfold dengan 5 fold. Metode ini mempartisi data latih menjadi 5 subset secara bergantian, di mana setiap fold dijamin memiliki proporsi kelas churn yang seimbang sesuai distribusi asli data (sekitar 20,4%). Hal ini penting agar estimasi performa tidak bias akibat distribusi kelas yang tidak merata. Hasil cross-validation melaporkan nilai F1-Score dan ROC-AUC pada masing-masing fold beserta rata-rata dan standar deviasinya. Rendahnya nilai standar deviasi di antara fold mengindikasikan bahwa model memiliki kemampuan generalisasi yang stabil dan tidak bergantung pada satu partisi data tertentu.

4.4.2 Logistic Regression


Model pertama yang dibangun adalah Logistic Regression sebagai baseline model. Sebelum pelatihan, data diproses melalui pipeline preprocessing yang terdiri dari dua tahap: StandardScaler diterapkan pada fitur numerik (age, tenure, balance, products_number, estimated_salary, active_member) untuk menyamakan skala agar Logistic Regression bekerja optimal, dan OneHotEncoder dengan parameter drop='first' diterapkan pada fitur kategorikal (country, gender) untuk menghindari multicollinearity akibat dummy variable trap. Kedua tahap ini dirangkai menggunakan ColumnTransformer dan dieksekusi dengan pola fit_transform pada data latih serta transform pada data uji untuk mencegah data leakage. Dataset dibagi dengan rasio 80:20 menggunakan stratify=y agar proporsi kelas churn terjaga pada kedua subset.

Model Logistic Regression diinisialisasi dengan tiga konfigurasi kunci: random_state=42 untuk reproduisibilitas, max_iter=1000 untuk memastikan konvergensi, dan class_weight='balanced' untuk memberikan bobot lebih besar pada kelas minoritas guna mengatasi class imbalance.

```
=== Logistic Regression Evaluation ===  
F1-Score      : 0.5062  
ROC-AUC Score: 0.7748
```


Gambar 4.4.2.1

Hasil evaluasi Logistic Regression pada data uji menghasilkan F1-Score sebesar 0.5062 dan ROC-AUC sebesar 0.7748. F1-Score menjadi metrik utama evaluasi karena mampu menyeimbangkan Precision dan Recall secara harmonis, yang sangat relevan pada kondisi *class imbalance* di mana akurasi saja tidak cukup menggambarkan kemampuan model mendeteksi kelas minoritas.



Gambar 4.4.2.2

Confusion Matrix memperlihatkan secara rinci hasil klasifikasi model: True Positive (TP) sebesar 286 menunjukkan jumlah nasabah churn yang berhasil terdeteksi dengan benar, True Negative (TN) sebesar 1,156 menunjukkan nasabah loyal yang diprediksi benar, False Positive (FP) sebesar 436 adalah nasabah loyal yang salah diprediksi churn, dan False Negative (FN) sebesar 122 adalah nasabah yang benar-benar churn namun luput terdeteksi. Dalam konteks bisnis perbankan, nilai FN merupakan kesalahan yang paling mahal karena bank kehilangan kesempatan melakukan intervensi retensi terhadap nasabah yang sebenarnya akan pergi.



Gambar 4.4.2.3

ROC Curve menggambarkan kemampuan model dalam membedakan kelas churn dan non-churn di seluruh nilai threshold. Nilai AUC sebesar 0.775 mengindikasikan bahwa model memiliki kemampuan diskriminasi yang baik meskipun strukturnya linear dan tidak mampu menangkap hubungan non-linear antar fitur.

```

=== Model Robustness Check ===


Train F1-Score : 0.4953
Test F1-Score  : 0.5062
F1 Gap        : 0.0109
-----
Train ROC-AUC  : 0.7695
Test ROC-AUC   : 0.7748
AUC Gap        : 0.0053

Conclusion :
The performance gap between the training and testing data is small,
indicating that the Logistic Regression model generalizes well
and does not show significant signs of overfitting.

```

Gambar 4.4.2.4

Pemeriksaan robustness menunjukkan selisih F1-Score antara data latih dan data uji sebesar 0.0109 dan selisih ROC-AUC sebesar 0.0053. Nilai gap yang kecil (di bawah 0,05) mengindikasikan bahwa model tidak mengalami overfitting yang signifikan dan memiliki kemampuan generalisasi yang memadai terhadap data baru.



Gambar 4.4.2.5

Analisis koefisien fitur mengungkapkan variabel-variabel yang paling berpengaruh terhadap prediksi churn. Fitur dengan koefisien positif tertinggi meningkatkan probabilitas churn, sementara fitur dengan koefisien negatif terbesar bersifat protektif. Temuan ini konsisten dengan hasil EDA sebelumnya dan menjadi dasar perbandingan terhadap *feature importance* Random Forest pada tahap berikutnya.

BAB V

Hasil & Diskusi

5.1 Hasil

Tabel Hasil Perbandingan Model

Metrik	Logistic Regression	Random Forest (Setelah Tuning)
F1-Score	0.5062	0,6364
ROC-AUC	0.7748	0.8602
True Positive (TP)	286	294
True Negative (TN)	1,156	1,370
False Positive (FP)	436	222
False Negative (FN)	122	114
Train F1	0.4953	0.7419
Test F1	0.5062	0.6240
F1 Gap	0.0109	0.1179
Train ROC-AUC	0.7695	0.9465
Test ROC-AUC	0.7748	0.8621
AUC Gap	0.0053	0.0844

Berdasarkan hasil evaluasi, Random Forest Classifier setelah proses hyperparameter tuning unggul dibandingkan Logistic Regression pada semua metrik utama. F1-Score naik dari 0,5062 menjadi 0,6364. Peningkatan sebesar 12,6 poin persentase. ROC-AUC juga meningkat signifikan dari 0,7748 menjadi 0,8602, yang berarti kemampuan model membedakan nasabah churn dari yang tidak meningkat cukup besar.

Dari sisi deteksi churn, False Negative (FN) Random Forest sebesar 114 lebih rendah dibanding Logistic Regression sebesar 122, artinya lebih sedikit nasabah yang benar-benar akan churn namun luput terdeteksi. Yang lebih signifikan, False Positive (FP) turun drastis dari 436 menjadi 222. Model Random Forest jauh lebih presisi dalam memberikan label churn sehingga bank tidak perlu mengalokasikan sumber daya retensi secara sia-sia ke nasabah yang sebenarnya loyal. Evaluasi Random Forest menggunakan threshold optimal 0,4230 yang diturunkan dari kurva

ROC melalui statistik Youden's J, sehingga lebih sensitif mendeteksi churn dibandingkan jika menggunakan threshold default 0,5.

Hasil cross-validation 5-fold pada data latih menunjukkan rata-rata F1-Score sebesar $0,6209 \pm 0,0144$ dan ROC-AUC sebesar $0,8615 \pm 0,0063$. Standar deviasi yang sangat kecil di kedua metrik mengonfirmasi bahwa performa model konsisten dan stabil di berbagai partisi data, tidak bergantung pada satu pembagian data tertentu.

Satu catatan penting dari robustness check: Random Forest menunjukkan F1 Gap sebesar 0,1179 dan AUC Gap sebesar 0,0844, yang mengindikasikan adanya kecenderungan overfitting ringan, model bekerja lebih baik pada data latih dibanding data uji.

Ini wajar mengingat kompleksitas model ensemble dengan 500 pohon, namun perlu diperhatikan untuk pengembangan ke depan. Sebaliknya, Logistic Regression menunjukkan gap yang sangat kecil (F1 Gap 0,0109, AUC Gap 0,0053), mencerminkan generalisasi yang sangat stabil meski performa absolutnya lebih rendah.

Dari analisis feature importance Random Forest, tiga fitur paling dominan adalah age (0,2987), products_number (0,1794), dan balance (0,1291) — ketiganya selaras dengan temuan EDA yang menunjukkan konsentrasi churn pada nasabah usia 40–50 tahun, nasabah dengan 3–4 produk, dan nasabah bersaldo tinggi.

5.2 Diskusi

Laporan ini telah membangun fondasi analisis yang solid melalui EDA dan pemodelan awal. Pada bagian ini, temuan-temuan tersebut dikembangkan lebih dalam dari sisi implikasi bisnis yang dapat langsung ditindaklanjuti oleh manajemen bank. Namun, sesuai arahan dosen memang masih banyak yang bisa dianalisa untuk keputusan bisnis yang lebih matang. Maka, dari itu temuan yang sudah dilakukan pada group project ini nantinya akan disempurnakan pada UAS.

5.2.1 Nasabah Usia Matang adalah Prioritas Retensi Utama

Usia terbukti menjadi faktor paling dominan dalam menentukan risiko churn. Nasabah di rentang usia 40–50 tahun adalah segmen yang paling rentan sekaligus paling bernilai bagi bank. Mereka berada di puncak produktivitas finansial, memiliki aset yang lebih besar, dan cukup melek finansial untuk aktif membandingkan penawaran antarbank. Bank sebaiknya merancang program loyalitas yang secara eksplisit menargetkan segmen ini, misalnya melalui penawaran produk *wealth management*, konsultasi perencanaan pensiun, atau skema bunga deposito yang lebih kompetitif dibanding pasar. Pendekatan yang bersifat personal seperti penugasan *relationship manager* khusus akan lebih efektif dibanding kampanye massal yang tidak tersegmentasi.

5.2.2 Hentikan Cross-Selling Agresif, Fokus pada Relevansi Produk

Salah satu temuan paling kritis dari proyek ini adalah bahwa mendorong nasabah memiliki lebih banyak produk justru meningkatkan risiko mereka pergi. Nasabah dengan 2 produk adalah kelompok paling loyal, sementara mereka yang memiliki 3 atau 4 produk hampir seluruhnya berujung churn. Ini mengindikasikan bahwa strategi *cross-selling* yang ada saat ini berjalan tanpa analisis kebutuhan yang memadai — produk dijual ke nasabah yang tidak benar-benar membutuhkannya, sehingga akumulasi biaya administrasi dan kompleksitas pengelolaan justru mendorong mereka keluar. Bank perlu mengevaluasi ulang insentif tim penjualan agar tidak semata berbasis volume produk, melainkan berbasis kepuasan dan retensi nasabah jangka panjang.

5.2.3 Nasabah Bersaldo Tinggi Butuh Penanganan Khusus, Bukan Penanganan Standar

Bank menghadapi risiko yang tidak simetris: nasabah yang paling mungkin pergi adalah justru nasabah yang membawa kapital terbesar. Kehilangan satu nasabah bersaldo tinggi jauh lebih berdampak terhadap dana pihak ketiga dibandingkan kehilangan puluhan nasabah bersaldo rendah. Model prediksi churn yang telah dibangun dalam proyek ini dapat langsung diintegrasikan sebagai sistem *early warning*, setiap nasabah dengan saldo tinggi yang mulai menunjukkan tanda inaktivitas harus segera mendapat intervensi proaktif, bukan menunggu hingga mereka menutup akun.

5.2.4 Jerman Butuh Strategi Tersendiri, Bukan Pendekatan Seragam

Tingginya churn di Jerman bukan sekadar anomali statistik, ini sinyal bahwa strategi produk yang bekerja di Prancis dan Spanyol tidak cukup kompetitif di pasar Jerman. Mengingat nasabah Jerman rata-rata memiliki saldo lebih tinggi, kompetitor di sana kemungkinan besar menawarkan imbal hasil atau layanan digital yang lebih menarik. Bank perlu melakukan riset kompetitif khusus di pasar Jerman dan mempertimbangkan diferensiasi produk secara regional bukan menerapkan satu kebijakan seragam untuk seluruh wilayah.

5.2.5 Loyalitas Tidak Datang Otomatis Seiring Waktu

Lamanya seorang nasabah bergabung tidak menjamin mereka akan bertahan. Churn terjadi merata di semua level masa keanggotaan, artinya bank belum berhasil membangun nilai yang cukup kuat untuk membuat nasabah merasa rugi jika pergi. Program retensi perlu dirancang sebagai upaya berkelanjutan di setiap tahap hubungan bukan hanya aktif di masa akuisisi awal lalu berhenti begitu nasabah sudah onboard. Nasabah yang sudah bergabung lebih dari 5 tahun pun perlu secara rutin mendapatkan penawaran yang relevan dan terasa dihargai.

Reference

Mufida, E., Andriansyah, D., & Hertyana, H. (2025). *Customer churn prediction pada sektor perbankan dengan model logistic regression dan random forest*. CO-SCIENCE (Computer Science), 5(1). <https://jurnal.bsi.ac.id/index.php/co-science/article/view/7576>